

模型使用统计报告

项目: Steel Pipe DB (Ikari Shinji)
统计周期: 2026-05-19 ~ 2026-05-21
生成时间: 2026-05-21

一、总体概况

指标	数值
总会话数（含用量）	90
总消息数	3,828
总输入 Tokens	17,816,482
总输出 Tokens	1,461,270
总推理 Tokens	536,512
总缓存读取 (Cache Hit)	423,380,035
总缓存写入 (Cache Write)	152,805
缓存命中率	95.96%
总费用	\$8.24
总运行时长（累加）	~1,107 小时
覆盖天数	3 天

缓存命中率 = 缓存读取 / (输入 + 缓存读取) = 423,380,035 / (17,816,482 + 423,380,035) ≈ 95.96%

二、日用量统计

日期	会话数	输入 Tokens	输出 Tokens	说明
2026-05-19	25	8,274,903	698,094	Phase 1 全栈实现（主会话 + 12 个子智能体）
2026-05-20	13	2,670,971	168,614	Phase 2/3 后端 + 测试用例生成
2026-05-21	52	6,870,608	594,562	Phase 2/3 剩余模块 + AGENTS.md 文档 + 推送到 GitHub
合计	90	17,816,482	1,461,270	

三、模型使用统计

3.1 按模型汇总

模型	提供商	活跃会话	输入 Tokens	输出 Tokens	推理 Tokens	缓存读取	缓存写入	费用
deepseek-v4-flash-free	opencode	61	16,600,213	1,317,444	510,524	380,075,843	152,805	\$0.04
deepseek-v4-pro	deepseek	27	869,764	130,089	25,883	42,377,472	0	\$8.20
gpt-4.1	github-copilot	2	342,211	12,108	0	436,736	0	\$0.00
gpt-4o	github-copilot	0	0	0	0	0	0	\$0.00

deepseek-v4-pro 和 gpt-4.1 在首次调用失败后作为回退使用，后期统一使用 general 子智能体（deepseek-v4-flash-free）完成剩余模块。

3.2 按智能体角色汇总

角色	会话数	输入 Tokens	输出 Tokens	推理 Tokens	缓存读取	费用
Sisyphus-Junior	57	9,297,456	736,948	285,095	234,397,056	\$8.20
Sisyphus (主智能体)	5	4,837,728	466,808	193,084	158,214,851	\$0.04
general	13	2,585,888	136,567	36,127	23,665,680	\$0.00
explore	15	1,096,155	119,967	22,128	6,787,220	\$0.00

四、主要开销分布

4.1 按会话排序（输入 Tokens TOP 10）

会话	用途	模型	输入 Tokens	输出 Tokens	费用
主会话 1 (ses_1bf76e22)	Phase 1~3 全栈实现 + 22 个子任务	deepseek-v4-flash-free	7,943,773	1,060,909	\$0.00
主会话 5 (ses_1b809021)	AGENTS.md + 排序优化 + 推送 GitHub	deepseek-v4-flash-free	2,348,405	246,963	\$0.04
库存模块 (ses_1bf72e96)	后端库存 Sisyphus-Junior	deepseek-v4-flash-free	1,101,932	124,875	\$0.00
出入库修复 (ses_1bd6f64c)	仓库出入库手动添加限制	deepseek-v4-flash-free	1,160,103	95,121	\$0.00
数据IO (ses_1bf6954f)	后端数据IO Sisyphus-Junior	deepseek-v4-flash-free	560,547	47,370	\$0.00
质量模块 (ses_1bf72d30)	后端质量 Sisyphus-Junior	deepseek-v4-flash-free	419,290	25,379	\$0.00
测试用例 (ses_1bd02cf4)	根据设计文档生成测试用例	deepseek-v4-flash-free	393,928	14,450	\$0.00
订单拆分 (ses_1bd5a62c)	采购/销售后端拆分 Sisyphus-Junior	deepseek-v4-flash-free	429,275	26,623	\$0.00
订单拆分前端 (ses_1bd5a32b)	采购/销售前端拆分 Sisyphus-Junior	deepseek-v4-flash-free	373,277	30,745	\$0.00
标签模块 (ses_1bf5b2c7)	后端标签 Sisyphus-Junior	deepseek-v4-flash-free	325,732	30,097	\$0.00

4.2 费用开销明细（仅付费模型）

会话	用途	模型	Tokens	费用
ses_1b7dc9e6	库存模块	deepseek-v4-pro	44,928 + 29,451	\$1.39
ses_1b7fa88e	认证模块	deepseek-v4-pro	151,145 + 14,957	\$0.94
ses_1b7e7cfc	钢管管理	deepseek-v4-pro	47,895 + 15,302	\$0.79
ses_1b7c76a6	前端钢管CRUD	deepseek-v4-pro	82,642 + 12,057	\$0.75
ses_1b7be7b4	前端库存	deepseek-v4-pro	58,399 + 22,524	\$0.86
ses_1b7c7955	前端用户管理	deepseek-v4-pro	102,355 + 7,981	\$0.61
其余 21 个	各模块	deepseek-v4-pro	合计 ~382k	~\$2.86

五、缓存效率分析

模型	输入 Tokens	缓存读取 (Cache Hit)	缓存命中率
deepseek-v4-flash-free	16,600,213	380,075,843	95.81%
deepseek-v4-pro	869,764	42,377,472	97.99%
gpt-4.1	342,211	436,736	56.07%
总计	17,816,482	423,380,035	95.96%

缓存命中率极高的原因是：多个子智能体共享了大量相同的上下文（项目配置、设计文档、任务列表），这些内容在首次加载后被缓存复用。

六、工作模式总结

6.1 执行阶段

阶段	时间	主要工作	主模型	子智能体数
Phase 1 (P0 MVP)	5/19 14:00~23:00	后端 4 模块 + 前端 4 模块	deepseek-v4-flash-free	12
Phase 2/3 实现	5/20~5/21	采购/销售/合同/报表/标签等	deepseek-v4-flash-free	15
代码优化	5/21	拆分模块、修复、 AGENTS.md	deepseek-v4-flash-free	6

6.2 费用结构

- **deepseek-v4-flash-free** 承担了 93% 的输入处理量，费用几乎为零
- **deepseek-v4-pro** 仅用于首次子智能体委托时付费回退到 GPT-4.1 失败后的替代模型
- **gpt-4.1** 仅尝试了 2 次但生成内容未被采纳
- 总花费 **\$8.24**，其中 99.5% 来自 deepseek-v4-pro

6.3 缓存策略有效性

- 全局缓存命中率 95.96% → 实际处理量等效减少 24 倍
- 项目设计文档和任务清单作为共享上下文被所有子智能体复用
- 仅第一个子智能体承担全量上下文加载成本

七、模型变体使用

模型变体	使用次数	说明
deepseek-v4-flash-free (default)	大部分	主智能体默认变体
deepseek-v4-flash-free (max)	部分复杂推理	用于代码生成
deepseek-v4-flash-free (high)	少量	用于高难度推理
deepseek-v4-flash-free (medium)	大部分子智能体	Sisyphus-Junior 默认
deepseek-v4-pro (default/medium)	部分	付费回退模型

生成自 OpenCode 本地会话数据库